

# Gaussian Mixture Model Note

FanmingL

2018 年 11 月 30 日

# 1 高斯混合模型

## 1.1 高斯混合模型的数学形式

$$\mathcal{N}(\mathbf{x}|\mu, \Sigma) = \frac{1}{(2\pi)^{d/2} \det(\Sigma)^{\frac{1}{2}}} \exp\left(-\frac{1}{2}(\mathbf{x} - \mu)^T \Sigma^{-1}(\mathbf{x} - \mu)\right) \quad (1)$$

式1为高斯分布的概率密度函数，其中  $\mu$  为变量的均值， $\Sigma$  为协方差矩阵， $d$  为向量维数，可以证明协方差矩阵是半正定的矩阵，所以协方差矩阵必然是实对称的。

假设某个分布由  $K$  个高斯分布构成，每次输出，都分两步，第一步从这  $K$  个高斯分布中随机选择一个，然后以此高斯分布输出。第  $k$  个高斯分布被选择到的概率为  $\pi_k$ ，其均值和方差分别为  $\mu_k, \Sigma_k$ ，为方便表示，引入一隐变量  $\mathbf{z}$ ，若  $\mathbf{z}$  的第  $k$  维， $z_k = 1$  表示选择了第  $k$  个高斯分布作为输出的分布，那么显然  $\mathbf{z}$  的  $K$  维中有且只有一维为 1。于是我们可以写出  $z_k$  的分布如下。

$$p(z_k = 1) = \pi_k \quad (2)$$

$\mathbf{z}$  的分布如下

$$p(\mathbf{z}) = \prod_{k=1}^K (\pi_k)^{z_k} \quad (3)$$

我们称  $p(\mathbf{z})$  为先验概率。

当我们已知  $\mathbf{z}$  时，即我们已知哪个高斯模型被选中时，条件概率密度分布可写为

$$p(\mathbf{x}|\mathbf{z}) = \prod_{k=1}^K \mathcal{N}(\mathbf{x}|\mu_k, \Sigma_k)^{z_k} \quad (4)$$

我们称  $p(\mathbf{x}|\mathbf{z})$  为似然概率。于是我们可以用全概率公式写出

$$p(\mathbf{x}) = \sum_{k=1}^K p(z_k = 1) \mathcal{N}(\mathbf{x}|\mu_k, \Sigma_k) = \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x}|\mu_k, \Sigma_k) \quad (5)$$

我们称  $p(\mathbf{x})$  为证据。当我们有了证据、似然、先验，我们可以用贝叶斯公式，得到后验概率为

$$\begin{aligned} p(z_k = 1|\mathbf{x}) &= \frac{p(z_k = 1)p(\mathbf{x}|z_k = 1)}{p(\mathbf{x})} \\ &= \frac{\pi_k \mathcal{N}(\mathbf{x}|\mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j \mathcal{N}(\mathbf{x}|\mu_j, \Sigma_j)} \end{aligned} \quad (6)$$

我们称  $p(z_k = 1|\mathbf{x})$  为后验概率密度分布，即当我们有了  $\mathbf{x}$  的样本之后，对  $z_k$  概率密度分布的估计。

## 1.2 EM 算法

实际上我们对参数  $\pi_k, \mu_k, \Sigma_k$  都一无所知，当我们拿到数据时，应当如何去估计这三者的值呢？自然是极大似然估计了。假设我们有  $N$  个样本，那么似然函数可以写为

$$\begin{aligned} L(\pi, \mu, \Sigma) &= \prod_{n=1}^N p(\mathbf{x}_n; \pi, \mu, \Sigma) \\ &= \prod_{n=1}^N \left( \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x}_n|\mu_k, \Sigma_k) \right) \end{aligned} \quad (7)$$

两边取对数，得到对数似然函数

$$\begin{aligned} l(\pi, \mu, \Sigma) &= \ln(L(\pi, \mu, \Sigma)) \\ &= \sum_{n=1}^N \ln \left( \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x}_n; \mu_k, \Sigma_k) \right) \end{aligned} \quad (8)$$

将  $l$  对  $\mu_k$  求偏导得

$$\begin{aligned} \frac{\partial l}{\partial \mu_k} &= \sum_{n=1}^N \frac{\pi_k \frac{\partial \mathcal{N}(\mathbf{x}_n; \mu_k, \Sigma_k)}{\partial \mu_k}}{\sum_{j=1}^K \pi_j \mathcal{N}(\mathbf{x}_n; \mu_j, \Sigma_j)} \\ &= \sum_{n=1}^N \frac{\pi_k \mathcal{N}(\mathbf{x}_n; \mu_k, \Sigma_k) \frac{\partial(-1/2(\mathbf{x}_n - \mu_k)^T \Sigma_k^{-1}(\mathbf{x}_n - \mu_k))}{\partial \mu_k}}{\sum_{j=1}^K \pi_j \mathcal{N}(\mathbf{x}_n; \mu_j, \Sigma_j)} \\ &= \sum_{n=1}^N \frac{\pi_k \mathcal{N}(\mathbf{x}_n; \mu_k, \Sigma_k) \Sigma_k^{-1}(\mathbf{x}_n - \mu_k)}{\sum_{j=1}^K \pi_j \mathcal{N}(\mathbf{x}_n; \mu_j, \Sigma_j)} \\ &= \sum_{n=1}^N \left[ \frac{\pi_k \mathcal{N}(\mathbf{x}_n; \mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j \mathcal{N}(\mathbf{x}_n; \mu_j, \Sigma_j)} \Sigma_k^{-1}(\mathbf{x}_n - \mu_k) \right] \end{aligned} \quad (9)$$

上式，中括号的左半部分恰是后验概率分布，即式6，为方便表示，令

$$\gamma(z_{nk}) = \frac{\pi_k \mathcal{N}(\mathbf{x}_n; \mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j \mathcal{N}(\mathbf{x}_n; \mu_j, \Sigma_j)} \quad (10)$$

所以  $l$  对  $\mu_k$  的偏导数为

$$\begin{aligned} \frac{\partial l}{\partial \mu_k} &= \sum_{n=1}^N [\gamma(z_{nk}) \Sigma_k^{-1}(\mathbf{x}_n - \mu_k)] \\ &= \sum_{n=1}^N [\gamma(z_{nk}) \Sigma_k^{-1} \mathbf{x}_n] - \sum_{n=1}^N [\gamma(z_{nk}) \Sigma_k^{-1} \mu_k] \\ &= \sum_{n=1}^N [\gamma(z_{nk}) \Sigma_k^{-1} \mathbf{x}_n] - \Sigma_k^{-1} \mu_k \sum_{n=1}^N \gamma(z_{nk}) \end{aligned} \quad (11)$$

为方便表示令

$$N_k = \sum_{n=1}^N \gamma(z_{nk}) \quad (12)$$

再令  $\frac{\partial l}{\partial \mu_k} = 0$  得

$$\begin{aligned} \sum_{n=1}^N [\gamma(z_{nk}) \Sigma_k^{-1} \mathbf{x}_n] &= \Sigma_k^{-1} \mu_k N_k \\ \sum_{n=1}^N [\gamma(z_{nk}) \mathbf{x}_n] &= \mu_k N_k \end{aligned} \quad (13)$$

即

$$\mu_k = \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) \mathbf{x}_n \quad (14)$$

至此求出了  $\mu_k$  的表示式即式14。

下面计算  $\pi_k$  的极大似然估计，由于  $\pi_k$  有如下约束

$$\sum_k^K \pi_k = 1 \quad (15)$$

故引入拉格朗日乘子  $\lambda$ ，将对数似然估计写为

$$l'(\pi, \mu, \Sigma) = \sum_{n=1}^N \left[ \ln \left( \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x}_n; \mu_k, \Sigma_k) \right) \right] + \lambda \left( \sum_{j=1}^K \pi_j - 1 \right) \quad (16)$$

$l'$  对  $\pi_k$  求偏导得

$$\frac{\partial l'}{\partial \pi_k} = \sum_{n=1}^N \frac{\mathcal{N}(\mathbf{x}_n; \mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j \mathcal{N}(\mathbf{x}_n; \mu_j, \Sigma_j)} + \lambda \quad (17)$$

令其为零，即

$$\sum_{n=1}^N \frac{\mathcal{N}(\mathbf{x}_n; \mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j \mathcal{N}(\mathbf{x}_n; \mu_j, \Sigma_j)} + \lambda = 0 \quad (18)$$

两边乘上  $\pi_k$  得

$$\sum_{n=1}^N \frac{\pi_k \mathcal{N}(\mathbf{x}_n; \mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j \mathcal{N}(\mathbf{x}_n; \mu_j, \Sigma_j)} + \lambda \pi_k = 0 \quad (19)$$

将每个  $k$  叠加，得到

$$\begin{aligned} \sum_{n=1}^N \frac{\sum_{j=1}^K \pi_k \mathcal{N}(\mathbf{x}_n; \mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j \mathcal{N}(\mathbf{x}_n; \mu_j, \Sigma_j)} + \lambda \sum_{j=1}^K \pi_j &= 0 \\ \sum_{n=1}^N 1 + \lambda \sum_{j=1}^K \pi_j &= 0 \\ N = -\lambda \sum_{j=1}^K \pi_j \end{aligned} \quad (20)$$

将约束条件代入上式，得

$$\lambda = -N \quad (21)$$

将式21代入至式19中得

$$\begin{aligned} \sum_{n=1}^N \frac{\pi_k \mathcal{N}(\mathbf{x}_n; \mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j \mathcal{N}(\mathbf{x}_n; \mu_j, \Sigma_j)} - N \pi_k &= 0 \\ \sum_{n=1}^N \gamma(z_{nk}) &= N \pi_k \\ N_k &= N \pi_k \\ \pi_k &= \frac{N_k}{N} \end{aligned} \quad (22)$$

于是我们得到  $\pi_k$  的表示式

$$\pi_k = \frac{N_k}{N} \quad (23)$$

下面推导  $\Sigma_k$  的极大似然估计，同样是令对数似然函数对  $\Sigma_k$  求偏导数。

$$\frac{\partial l}{\partial \Sigma_k} = \sum_{n=1}^N \frac{\pi_k \frac{\partial \mathcal{N}(\mathbf{x}_n; \mu_k, \Sigma_k)}{\partial \Sigma_k}}{\sum_{j=1}^K \pi_j \mathcal{N}(\mathbf{x}_n; \mu_j, \Sigma_j)} \quad (24)$$

下面单独求  $\frac{\partial \mathcal{N}(\mathbf{x}_n; \mu_k, \Sigma_k)}{\partial \Sigma_k}$  的值

$$\begin{aligned}
\frac{\partial \mathcal{N}(\mathbf{x}_n; \mu_k, \Sigma_k)}{\partial \Sigma_k} &= \frac{\partial \frac{1}{(2\pi)^{d/2} \sqrt{\det(\Sigma_k)}} \exp(-\frac{1}{2}(\mathbf{x}_n - \mu_k)^T \Sigma_k^{-1} (\mathbf{x}_n - \mu_k))}{\partial \Sigma_k} \\
&= \frac{1}{(2\pi)^{d/2}} \frac{\partial \det(\Sigma_k)^{-\frac{1}{2}} \exp(-\frac{1}{2}(\mathbf{x}_n - \mu_k)^T \Sigma_k^{-1} (\mathbf{x}_n - \mu_k))}{\partial \Sigma_k} \\
&= \frac{1}{(2\pi)^{d/2}} \left[ \exp(-\frac{1}{2}(\mathbf{x}_n - \mu_k)^T \Sigma_k^{-1} (\mathbf{x}_n - \mu_k)) \frac{\partial \det(\Sigma_k)^{-\frac{1}{2}}}{\partial \Sigma_k} \right. \\
&\quad \left. + \det(\Sigma_k)^{-\frac{1}{2}} \frac{\partial \exp(-\frac{1}{2}(\mathbf{x}_n - \mu_k)^T \Sigma_k^{-1} (\mathbf{x}_n - \mu_k))}{\partial \Sigma_k} \right] \\
&= \frac{1}{(2\pi)^{d/2}} \left[ \exp(-\frac{1}{2}(\mathbf{x}_n - \mu_k)^T \Sigma_k^{-1} (\mathbf{x}_n - \mu_k)) \left( -\frac{1}{2} \det(\Sigma_k)^{-\frac{3}{2}} \det(\Sigma_k) \Sigma_k^{-1} \right) \right. \\
&\quad \left. - \frac{1}{2} \det(\Sigma_k)^{-\frac{1}{2}} \exp(-\frac{1}{2}(\mathbf{x}_n - \mu_k)^T \Sigma_k^{-1} (\mathbf{x}_n - \mu_k)) \frac{\partial ((\mathbf{x}_n - \mu_k)^T \Sigma_k^{-1} (\mathbf{x}_n - \mu_k))}{\partial \Sigma_k} \right] \\
&= \frac{1}{(2\pi)^{d/2}} \exp(-\frac{1}{2}(\mathbf{x}_n - \mu_k)^T \Sigma_k^{-1} (\mathbf{x}_n - \mu_k)) \left[ \left( -\frac{1}{2} \det(\Sigma_k)^{-\frac{1}{2}} \Sigma_k^{-1} \right) \right. \\
&\quad \left. - \frac{1}{2} \det(\Sigma_k)^{-\frac{1}{2}} (-\Sigma_k^{-1} (\mathbf{x}_n - \mu_k) (\mathbf{x}_n - \mu_k)^T \Sigma_k^{-1}) \right] \\
&= -\frac{1}{2} \det(\Sigma_k)^{-\frac{1}{2}} \frac{1}{(2\pi)^{d/2}} \exp(-\frac{1}{2}(\mathbf{x}_n - \mu_k)^T \Sigma_k^{-1} (\mathbf{x}_n - \mu_k)) [\Sigma_k^{-1} \\
&\quad - \Sigma_k^{-1} (\mathbf{x}_n - \mu_k) (\mathbf{x}_n - \mu_k)^T \Sigma_k^{-1}] \\
&= -\frac{1}{2} \mathcal{N}(\mathbf{x}_n; \mu_k, \Sigma_k) [\Sigma_k^{-1} - \Sigma_k^{-1} (\mathbf{x}_n - \mu_k) (\mathbf{x}_n - \mu_k)^T \Sigma_k^{-1}]
\end{aligned} \tag{25}$$

所以

$$\begin{aligned}
\frac{\partial l}{\partial \Sigma_k} &= -\frac{1}{2} \sum_{n=1}^N \left[ \frac{\pi_k \mathcal{N}(\mathbf{x}_n; \mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j \mathcal{N}(\mathbf{x}_n; \mu_j, \Sigma_j)} (\Sigma_k^{-1} - \Sigma_k^{-1} (\mathbf{x}_n - \mu_k) (\mathbf{x}_n - \mu_k)^T \Sigma_k^{-1}) \right] \\
&= -\frac{1}{2} \sum_{n=1}^N [\gamma(z_{nk}) (\Sigma_k^{-1} - \Sigma_k^{-1} (\mathbf{x}_n - \mu_k) (\mathbf{x}_n - \mu_k)^T \Sigma_k^{-1})] \\
&= -\frac{1}{2} \left[ \sum_{n=1}^N (\gamma(z_{nk}) \Sigma_k^{-1}) - \sum_{n=1}^N (\gamma(z_{nk}) \Sigma_k^{-1} (\mathbf{x}_n - \mu_k) (\mathbf{x}_n - \mu_k)^T \Sigma_k^{-1}) \right]
\end{aligned} \tag{26}$$

令偏导为零，得

$$\begin{aligned}
\sum_{n=1}^N (\gamma(z_{nk}) \Sigma_k^{-1}) &= \sum_{n=1}^N (\gamma(z_{nk}) \Sigma_k^{-1} (\mathbf{x}_n - \mu_k) (\mathbf{x}_n - \mu_k)^T \Sigma_k^{-1}) \\
\Sigma_k \sum_{n=1}^N \gamma(z_{nk}) &= \sum_{n=1}^N \gamma(z_{nk}) (\mathbf{x}_n - \mu_k) (\mathbf{x}_n - \mu_k)^T \\
\Sigma_k N_k &= \sum_{n=1}^N \gamma(z_{nk}) (\mathbf{x}_n - \mu_k) (\mathbf{x}_n - \mu_k)^T \\
\Sigma_k &= \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) (\mathbf{x}_n - \mu_k) (\mathbf{x}_n - \mu_k)^T
\end{aligned} \tag{27}$$

于是我们得到  $\Sigma_k$  的表示式

$$\Sigma_k = \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) (\mathbf{x}_n - \mu_k)(\mathbf{x}_n - \mu_k)^T \quad (28)$$

至此我们用  $\gamma(z_{nk})$  表示出了  $\mu_k, \Sigma_k, \pi_k$  的极大似然估计，分别为式14，式28，式23。但是有个问题，后验概率  $\gamma(z_{nk})$  由式10给出，它本身就与  $\mu_k, \Sigma_k, \pi_k$  有很复杂的关系。虽然不可以直接得到  $\mu_k, \Sigma_k, \pi_k$  的闭式解，但是，这也暗示了我们，可以利用迭代的方式，去逼近最优解。即 EM 算法，高斯混合模型的 EM 算法可以表示为算法1。

---

**Algorithm 1** 对于高斯混合模型的 EM 算法

---

初始化每个高斯混合模型的均值  $\mu_k$ ，协方差矩阵  $\Sigma_k$ ，以及对应的  $\pi_k$

**while** 算法没有收敛 **do**

**for**  $n \in [1, N]$  **do**

**for**  $k \in [1, K]$  **do**

      E 步：计算  $\gamma(z_{nk}) = \frac{\pi_k \mathcal{N}(\mathbf{x}_n; \mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j \mathcal{N}(\mathbf{x}_n; \mu_j, \Sigma_j)}$

**end for**

**end for**

**for**  $k \in [1, K]$  **do**

    M 步计算  $N_k$ ：计算  $N_k = \sum_{n=1}^N \gamma(z_{nk})$

    M 步计算  $\mu_k$ ：计算  $\mu_k^{new} = \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) \mathbf{x}_n$

    M 步计算  $\Sigma_k$ ：计算  $\Sigma_k^{new} = \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) (\mathbf{x}_n - \mu_k^{new})(\mathbf{x}_n - \mu_k^{new})^T$

    M 步计算  $\pi_k$ ：计算  $\pi_k^{new} = \frac{N_k}{N}$

**end for**

  计算对数似然概率  $l(\pi, \mu, \Sigma) = \sum_{n=1}^N \ln \left( \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x}_n; \mu_k, \Sigma_k) \right)$

**if**  $l(\pi, \mu, \Sigma)$  变化很小时 **then**

    算法收敛，迭代结束

**end if**

**end while**

---

### 1.3 在线 EM 算法

实际上 EM 算法的 M 步，可以用梯度上升法求解，为方便，将之前得到的对数似然函数对  $\mu_k, \Sigma_k, \pi_k$  的偏导数写在下方。

$$\begin{aligned}
\frac{\partial l}{\partial \mu_k} &= \sum_{n=1}^N [\gamma(z_{nk}) \Sigma_k^{-1} (\mathbf{x}_n - \mu_k)] \\
&\approx N \mathbb{E}_{z_k=1|\mathbf{x}_n} [\Sigma_k^{-1} (\mathbf{x}_n - \mu_k)] \\
\frac{\partial l}{\partial \Sigma_k} &= -\frac{1}{2} \sum_{n=1}^N [\gamma(z_{nk}) (\Sigma_k^{-1} - \Sigma_k^{-1} (\mathbf{x}_n - \mu_k)(\mathbf{x}_n - \mu_k)^T \Sigma_k^{-1})] \\
&\approx -\frac{N}{2} \mathbb{E}_{z_k=1|\mathbf{x}_n} [\Sigma_k^{-1} - \Sigma_k^{-1} (\mathbf{x}_n - \mu_k)(\mathbf{x}_n - \mu_k)^T \Sigma_k^{-1}] \\
\frac{\partial l'}{\partial \pi_k} &= \frac{1}{\pi_k} \sum_{n=1}^N \gamma(z_{nk}) - N \\
&\approx N \left( \mathbb{E}_{z_k=1|\mathbf{x}_n} \left[ \frac{1}{\pi_k} \right] - 1 \right)
\end{aligned} \tag{29}$$

所以根据梯度上升法，三者的迭代公式为

$$\begin{aligned}
\mu_k^{new} &= \mu_k + \alpha N \mathbb{E}_{z_k=1|\mathbf{x}_n} [\Sigma_k^{-1} (\mathbf{x}_n - \mu_k)] \\
\Sigma_k^{new} &= \Sigma_k - \alpha \frac{N}{2} \mathbb{E}_{z_k=1|\mathbf{x}_n} [\Sigma_k^{-1} - \Sigma_k^{-1} (\mathbf{x}_n - \mu_k^{new})(\mathbf{x}_n - \mu_k^{new})^T \Sigma_k^{-1}] \\
\pi_k^{new} &= \pi_k + \alpha N \left( \mathbb{E}_{z_k=1|\mathbf{x}_n} \left[ \frac{1}{\pi_k} \right] - 1 \right)
\end{aligned} \tag{30}$$

这三个迭代公式还是要使用到期望操作，这个操作去要用到所有的数据点，不妨用当前值取近似期望。

$$\begin{aligned}
\mu_k^{new} &= \mu_k + \alpha N \gamma(z_{nk}) [\Sigma_k^{-1} (\mathbf{x}_n - \mu_k)] \\
\Sigma_k^{new} &= \Sigma_k - \alpha \frac{N}{2} \gamma(z_{nk}) [\Sigma_k^{-1} - \Sigma_k^{-1} (\mathbf{x}_n - \mu_k^{new})(\mathbf{x}_n - \mu_k^{new})^T \Sigma_k^{-1}] \\
\pi_k^{new} &= \pi_k + \alpha N \left( \gamma(z_{nk}) \left[ \frac{1}{\pi_k} \right] - 1 \right)
\end{aligned} \tag{31}$$

整理得

$$\begin{aligned}
\mu_k^{new} &= (I - \alpha N \gamma(z_{nk}) \Sigma_k^{-1}) \mu_k + \alpha N \gamma(z_{nk}) \Sigma_k^{-1} \mathbf{x}_n \\
\Sigma_k^{new} &= (I - \alpha \frac{N}{2} \gamma(z_{nk}) \Sigma_k^{-2}) \Sigma_k + \alpha \frac{N}{2} \gamma(z_{nk}) \Sigma_k^{-1} (\mathbf{x}_n - \mu_k)(\mathbf{x}_n - \mu_k)^T \Sigma_k^{-1} \\
\pi_k^{new} &= (1 - \frac{\alpha N}{\pi_k}) \pi_k + \frac{\alpha N \gamma(z_{nk})}{\pi_k}
\end{aligned} \tag{32}$$

在之后的应用中，我们常假设  $\Sigma_k$  为对角阵，于是  $\Sigma$  得更新公式化为，

$$\Sigma_k^{new} = (I - \alpha \frac{N}{2} \gamma(z_{nk}) \Sigma_k^{-2}) \Sigma_k + \alpha \frac{N}{2} \gamma(z_{nk}) \Sigma_k^{-2} \text{diag}((\mathbf{x}_n - \mu_k)(\mathbf{x}_n - \mu_k)^T) \tag{33}$$

其中  $\text{diag}(*)$  表示取 \* 的对角元素构成对角矩阵。实际上三式都能够写成这样的形式，即

$$\begin{aligned}
\mu_k^{new} &= (I - \rho_\mu) \mu_k + \rho_\mu \mathbf{x}_n \\
\Sigma_k^{new} &= (I - \rho_\Sigma) \Sigma_k + \rho_\Sigma \text{diag}((\mathbf{x}_n - \mu_k)(\mathbf{x}_n - \mu_k)^T) \\
\pi_k^{new} &= (1 - \rho_\pi) \pi_k + \rho_\pi \gamma(z_{nk})
\end{aligned} \tag{34}$$

式34便是在线更新  $\mu_k, \Sigma_k, \pi_k$  的迭代公式，可见迭代过程只与当前的观测值有关，学习速度与  $\rho_\mu, \rho_\Sigma, \rho_\pi$  有关。

## 1.4 基于高斯混合模型的背景建模

对于个视频，每个像素的位置有 RGB 三个通道，可以把每个像素看成是维数为 3 的随机过程，我们可以将该过程用高斯混合模型去拟合，高斯分量个数  $K$  一般取 3 至 5，均假设协方差矩阵为对角矩阵，即不同通道的数据完全不相关。即我们对每个像素都建立一个高斯混合模型。

### 1.4.1 初始化 GMM

我们用视频的第一幅图片去初始化每个像素点的高斯混合模型，具体方法是：对所有高斯分量，其协方差都取同一个合适的值，均值均设为零，权重  $\pi_k$  均设为 0，再任取一高斯分量，令其均值等于该像素点的值，权重设为 1。

### 1.4.2 更新参数

更新参数的步骤，形式如式34所示，只是对于学习率  $\rho_\mu, \rho_\Sigma, \rho_\pi$  的设定有所不同。算法描述如算法2。

算法2的简单理解就是，首先判断当前像素点是否属于高斯混合模型的某个分量。如果不属于任何一个，则把权重最低的高斯分量删去，用当前像素点初始化新的高斯分量；而如果属于多个，则取权重最大的那个作为匹配到的高斯分量。对匹配到的高斯分量更新  $\mu_k, \Sigma_k, \pi_k$ ，更新公式为

$$\begin{aligned}\pi_k^{new} &= (1 - \alpha)\pi_k + \alpha \\ \mu_k^{new} &= (1 - \rho)\mu_k + \rho\mathbf{p}_i \\ \Sigma_k^{new} &= (I - \rho)\Sigma_k + \rho\text{diag}((\mathbf{x}_n - \mu_k)(\mathbf{x}_n - \mu_k)^T)\end{aligned}\tag{35}$$

其中  $\alpha$  为学习率， $\rho$  定义为

$$\rho = \alpha\mathcal{N}(\mathbf{p}_i; \mu_k, \Sigma_k)\tag{36}$$

对于没有匹配到的高斯分量，只更新权重  $\pi_k$ 。

$$\pi_k^{new} = (1 - \alpha)\pi_k\tag{37}$$

### 1.4.3 总结

若直接用 EM 算法对背景进行建模，计算量会非常大，而这里给出的算法，则只需要遍历一边图像就可以更新 GMM 的参数，可谓是非常高效，同样在实际操作中，也显示出了非常好的效果。但是，缺点也是有的，我们必须设定一个  $K$  值，而且 GMM 的初始化也对收敛过程有很大的影响。在之后的十几年中，有很多新的方法都是针对这两个问题提出的。



---

**Algorithm 2** 对背景基于 GMM 建模的方法

---

初始化每个像素点的高斯混合模型

初始化学习率  $\alpha$

**while** true **do**

    读取一张图像  $\mathbf{P}$

**for** 每个像素  $\mathbf{p}_i \in \mathbf{P}$  **do**

$index = -1, weight = 0$

**for**  $k \in [1, K]$  **do**

            当前像素对应的 GMM 的参数分别为  $\mu_{ik}, \Sigma_{ik}, \pi_{ik}$

**if** 每个通道的像素值  $|p_{ic} - \mu_{ik}| < 2.5\Sigma_{ikcc}$  **then**

**if**  $\pi_{ik} > weight$  **then**

$index = k$

$weight = \pi_{ik}$

**end if**

**end if**

**end for**

**if**  $index = -1$  **then**

            判断该像素点为前景

            删掉最小权重  $\pi_{ik}$  对应的高斯分量

            用当前像素值  $\mathbf{p}_i$  初始化新的高斯分量

**else**

            判断该像素为背景

**for**  $k \in [1, K]$  **do**

$\pi_{ik}^{new} = (1 - \alpha)\pi_{ik} + \alpha(M_{ik})$

                其中  $M_{ik}$  仅在  $k = index$  时为 1，其余为 0

**end for**

            令  $k = index$

$\rho = \alpha\mathcal{N}(\mathbf{p}_i; \mu_k, \Sigma_k)$

            更新  $\mu_k^{new} = (1 - \rho)\mu_k + \rho\mathbf{p}_i$

            更新  $\Sigma_k^{new} = (I - \rho)\Sigma_k + \rho\text{diag}((\mathbf{x}_n - \mu_k)(\mathbf{x}_n - \mu_k)^T)$

**end if**

**end for**

**end while**

---