

Kernelized Correlation Filters Notes

FanmingL

2018 年 11 月 28 日



图 1: 左图为检测到物体的图像, 需要寻找到右图中的物体

1 核相关滤波器

1.1 问题提出

若我们有两张图片, 在两张图片中均有某物体, 在第一张图片中检测到该物体, 那么如何在第二张图片中寻找该物体呢?

一个很直观的思想是: 罗列出第一张图所有可能的平移变换, 比如, 这是一张 75×75 的图片, 该图片的左上角在 $(0,0)$ 处, 移动图片, 使得图片左上角移动至其余的 $75 \times 75 - 1$ 像素处, 超出边界的像素补充至上边界和左边界。这样我们可以得到 75×75 (包括原图) 张图像, 将图1中右图与这 75×75 张图像对比, 计算图像的相关性, 找到最大相关性的图像, 该图像对应的平移便是图1左图中物体到图1右图中物体的平移。

这篇文章的思想也大抵如此, 但是它用非常精妙的技巧将计算复杂度降低到了 $O(n \log n)$ 。

1.2 问题的数学表示

1.2.1 循环矩阵

如第1.1节所示, 我们需要得到所有能够移动得到的图片, 那么应该如何表示呢?

只需要将图像 (为了方便起见, 这里暂时用灰度图像) 化为列向量 \mathbf{x} , 然后对 \mathbf{x} 做循环位移再转变回矩阵即可。循环位移即左乘 \mathbf{P} 矩阵。

$$\mathbf{P} = \begin{bmatrix} 0 & 0 & 0 & \cdots & 1 \\ 1 & 0 & 0 & \cdots & 0 \\ 0 & 1 & 0 & \cdots & 0 \\ \vdots & \vdots & \ddots & \ddots & \vdots \\ 0 & 0 & \cdots & 1 & 0 \end{bmatrix} \quad (1)$$

可以看出 $\mathbf{P}\mathbf{x} = [x_n, x_1, x_2, \cdots, x_{n-1}]^T$ 即为 \mathbf{x} 向下移动一次得到的新向量。由此我们可以得到 n 个平移得到的向量。

$$\{\mathbf{P}^u \mathbf{x} | u = 0, \cdots, n-1\} \quad (2)$$

我们将所有这些向量拼成一个矩阵，即

$$\mathbf{X} = \begin{bmatrix} x_1 & x_2 & x_3 & \cdots & x_n \\ x_n & x_1 & x_2 & \cdots & x_{n-1} \\ x_{n-1} & x_n & x_1 & \cdots & x_{n-2} \\ \vdots & \vdots & \ddots & \ddots & \vdots \\ x_2 & x_3 & x_4 & \cdots & x_1 \end{bmatrix} \quad (3)$$

我们定义操作 $C(\mathbf{x}) \Rightarrow X$ ，即以 \mathbf{x}^T 为第一行构造循环矩阵。

1.2.2 用岭回归求解问题

我们尝试用岭回归求解第1.1节描述的问题，首先设 \mathbf{x} 为原始的图像， \mathbf{x}_i 定义为

$$\mathbf{x}_i = \mathbf{P}^{i-1} \mathbf{x} \quad i = 1, \dots, n \quad (4)$$

下一步我们需要得到一个线性回归模型

$$f(\mathbf{z}) = \mathbf{z}^T \mathbf{w} \quad (5)$$

我们希望用它来判断 \mathbf{z} 与原始图像的相关性大小。

为了构造训练集我们为每一个图像 \mathbf{x}_i 给定一个与原始图像的相关系数，用 y_i 表示。给 y_i 赋值的原理是 \mathbf{x}_i 偏移原始图像越远，相关性越小。 y_i 可以用高斯函数去给定，即 $i = 0$ 时 $y_i = 1$ 其余 y_i 按照其图像左上角与原始图像左上角的距离按照高斯函数衰减（即偏的越远， y_i 越小，这是很好理解的）。

于是我们有了我们的训练样本 \mathbf{X} 和标签 \mathbf{y} ，接下来我们用岭回归去得到线性模型的系数 \mathbf{w} 。

岭回归的优化目标是 최소화经验风险和结构风险之和，即

$$\min \sum_i^n ((f(\mathbf{x}_i) - y_i)^2 + \lambda \|\mathbf{w}\|^2) \quad (6)$$

写成矩阵形式

$$\min J(\mathbf{w}) = (\mathbf{X}\mathbf{w} - \mathbf{y})^T (\mathbf{X}\mathbf{w} - \mathbf{y}) + \lambda \mathbf{w}^T \mathbf{w} \quad (7)$$

对 $J(\mathbf{w})$ 求偏导，并使偏导为零得到

$$\mathbf{w} = (\mathbf{X}^T \mathbf{X} + \lambda I)^{-1} \mathbf{X}^T \mathbf{y} \quad (8)$$

更一般的，对于 \mathbf{X} 为复矩阵的情况

$$\mathbf{w} = (\mathbf{X}^H \mathbf{X} + \lambda I)^{-1} \mathbf{X}^H \mathbf{y} \quad (9)$$

至此我们用循环矩阵构造的训练集得到了我们的回归模型，对图1右图的检测也只需要将该图化为列向量 \mathbf{z} ，然后计算 $\mathbf{f}(\mathbf{z}) = C(\mathbf{z})\mathbf{w}$ ， $\mathbf{f}(\mathbf{z})$ 最大值对应的平移就是右图中物体相对于左图中物体的估计位置。

但是很显然，这样一种运算代价实在是太高了，所以本文根据循环矩阵的特性，对上述计算大大化简。

1.3 用循环矩阵的特征值分解简化结果

1.3.1 离散傅立叶变换

若有一 N 维离散序列 \mathbf{x} 其离散傅立叶变换可以写为

$$\hat{x}_k = \sum_{n=0}^N \exp(-j \frac{2\pi}{N} nk) x_n \quad (10)$$

其逆变换可写为

$$x_n = \frac{1}{N} \sum_{k=0}^N \exp(j \frac{2\pi}{N} nk) \hat{x}_k \quad (11)$$

根据式10可以将式10写成矩阵形式即

$$\hat{\mathbf{x}} = \mathbf{G}\mathbf{x} \quad (12)$$

其中 $G_{kn} = \exp(-j \frac{2\pi}{N} nk)$ 。可以看出 $G_{kn} = G_{nk} = \exp(-j \frac{2\pi}{N} nk)$ ，所以

$$\mathbf{G} = \mathbf{G}^T \quad (13)$$

逆变换可以写为

$$\mathbf{x} = \frac{1}{N} \mathbf{G}^* \hat{\mathbf{x}} \quad (14)$$

我们可以来看看 \mathbf{G} 是否是酉矩阵（即是否满足 $\mathbf{G}^H \mathbf{G} = \mathbf{I}$ ）

$$\begin{aligned} \mathbf{x} &= \frac{1}{N} \mathbf{G}^* \hat{\mathbf{x}} \\ \mathbf{x} &= \frac{1}{N} \mathbf{G}^* \mathbf{G} \mathbf{x} \\ \mathbf{x} &= \frac{1}{N} \mathbf{G}^H \mathbf{G} \mathbf{x} \end{aligned} \quad (15)$$

即满足 $\frac{1}{N} \mathbf{G}^H \mathbf{G} = \mathbf{I}$ ，为了之后推导方便，我们令

$$\mathbf{F} = \frac{1}{\sqrt{N}} \mathbf{G} \quad (16)$$

\mathbf{F} 显然满足对称性

$$\mathbf{F}^T = \mathbf{F} \quad (17)$$

且 \mathbf{F} 是酉矩阵

$$\mathbf{F}^H \mathbf{F} = \mathbf{F} \mathbf{F}^H = \mathbf{I} \quad (18)$$

且基于 \mathbf{F} 的离散傅立叶变换可写为

$$\hat{\mathbf{x}} = \mathcal{F}(\mathbf{x}) = \sqrt{N} \mathbf{F} \mathbf{x} \quad (19)$$

逆离散傅立叶变换为

$$\mathbf{x} = \mathcal{F}^{-1}(\hat{\mathbf{x}}) = \frac{1}{\sqrt{N}} \mathbf{F}^H \hat{\mathbf{x}} \quad (20)$$

式19、式20、式17、式18在之后的推导中将会多次使用！

1.3.2 循环矩阵的特征值分解

若某一方阵 \mathbf{X} 的元素 X_{ij} 的值只与 $(i - j)$ 的大小有关, 那么矩阵 \mathbf{X} 为循环矩阵且, 矩阵 \mathbf{X} 可以进行特征值分解

$$\mathbf{X} = \mathbf{F} \text{diag}(\hat{\mathbf{x}}) \mathbf{F}^H \quad (21)$$

其中 $\hat{\mathbf{x}} = \mathcal{F}(\mathbf{x})$, 即 \mathbf{x} 的离散傅立叶变换, \mathbf{F} 即式16所定义的。

1.3.3 训练过程的简化

我们回到式9, 用式21对其进行化简。我们有

$$\begin{aligned} \mathbf{X}^H \mathbf{X} &= \mathbf{F} \text{diag}(\hat{\mathbf{x}}^*) \mathbf{F}^H \mathbf{F} \text{diag}(\hat{\mathbf{x}}) \mathbf{F}^H \\ &= \mathbf{F} \text{diag}(\hat{\mathbf{x}}^*) \text{diag}(\hat{\mathbf{x}}) \mathbf{F}^H \\ &= \mathbf{F} \text{diag}(\hat{\mathbf{x}}^* \odot \hat{\mathbf{x}}) \mathbf{F}^H \end{aligned} \quad (22)$$

所以

$$\begin{aligned} \mathbf{X}^H \mathbf{X} + \lambda I &= \mathbf{F} \text{diag}(\hat{\mathbf{x}}^* \odot \hat{\mathbf{x}}) \mathbf{F}^H + \lambda \mathbf{F} \mathbf{F}^H \\ &= \mathbf{F} \text{diag}(\hat{\mathbf{x}}^* \odot \hat{\mathbf{x}} + \lambda) \mathbf{F}^H \end{aligned} \quad (23)$$

所以

$$(\mathbf{X}^H \mathbf{X} + \lambda I)^{-1} = \mathbf{F} \text{diag}\left(\frac{1}{\hat{\mathbf{x}}^* \odot \hat{\mathbf{x}} + \lambda}\right) \mathbf{F}^H \quad (24)$$

$$\begin{aligned} (\mathbf{X}^T \mathbf{X} + \lambda I)^{-1} \mathbf{X}^H &= \mathbf{F} \text{diag}\left(\frac{1}{\hat{\mathbf{x}}^* \odot \hat{\mathbf{x}} + \lambda}\right) \mathbf{F}^H \mathbf{F} \text{diag}(\hat{\mathbf{x}}^*) \mathbf{F}^H \\ &= \mathbf{F} \text{diag}\left(\frac{1}{\hat{\mathbf{x}}^* \odot \hat{\mathbf{x}} + \lambda}\right) \text{diag}(\hat{\mathbf{x}}^*) \mathbf{F}^H \\ &= \mathbf{F} \text{diag}\left(\frac{\hat{\mathbf{x}}^*}{\hat{\mathbf{x}}^* \odot \hat{\mathbf{x}} + \lambda}\right) \mathbf{F}^H \end{aligned} \quad (25)$$

所以

$$\begin{aligned} \mathbf{w} &= \mathbf{F} \text{diag}\left(\frac{\hat{\mathbf{x}}^*}{\hat{\mathbf{x}}^* \odot \hat{\mathbf{x}} + \lambda}\right) \mathbf{F}^H \mathbf{y} \\ \mathbf{F}^H \mathbf{w} &= \text{diag}\left(\frac{\hat{\mathbf{x}}^*}{\hat{\mathbf{x}}^* \odot \hat{\mathbf{x}} + \lambda}\right) \mathbf{F}^H \mathbf{y} \\ \mathbf{F}^T \mathbf{w}^* &= \text{diag}\left(\frac{\hat{\mathbf{x}}}{\hat{\mathbf{x}}^* \odot \hat{\mathbf{x}} + \lambda}\right) \mathbf{F}^T \mathbf{y}^* \\ \mathbf{F}^T \mathbf{w} &= \text{diag}\left(\frac{\hat{\mathbf{x}}}{\hat{\mathbf{x}}^* \odot \hat{\mathbf{x}} + \lambda}\right) \mathbf{F}^T \mathbf{y} \\ \mathbf{F} \mathbf{w} &= \text{diag}\left(\frac{\hat{\mathbf{x}}}{\hat{\mathbf{x}}^* \odot \hat{\mathbf{x}} + \lambda}\right) \mathbf{F} \mathbf{y} \\ \mathcal{F}(\mathbf{w}) &= \text{diag}\left(\frac{\hat{\mathbf{x}}}{\hat{\mathbf{x}}^* \odot \hat{\mathbf{x}} + \lambda}\right) \mathcal{F}(\mathbf{y}) \end{aligned} \quad (26)$$

最后得到

$$\hat{\mathbf{w}} = \text{diag}\left(\frac{\hat{\mathbf{x}}}{\hat{\mathbf{x}}^* \odot \hat{\mathbf{x}} + \lambda}\right) \hat{\mathbf{y}} \quad (27)$$

左乘对角阵是对行加权, 即

$$\hat{\mathbf{w}} = \frac{\hat{\mathbf{x}} \odot \hat{\mathbf{y}}}{\hat{\mathbf{x}}^* \odot \hat{\mathbf{x}} + \lambda} \quad (28)$$

至此，我们将 \mathbf{w} 的表达式化简至此，大部分的运算量都花在离散傅立叶变换上，而得益于快速傅立叶变换，时间复杂度为 $O(n \log n)$ 的算法，这个算法的时间复杂度也变成了 $O(n \log n)$ 。

1.3.4 检测过程的简化

于是训练过程可以用 $O(n \log n)$ 的算法代替，那么检测过程呢？

$$\begin{aligned}\mathbf{f}(\mathbf{z}) &= C(\hat{\mathbf{z}})\mathbf{w} \\ &= \mathbf{F} \text{diag}(\hat{\mathbf{z}}) \mathbf{F}^H \mathbf{w} \\ \mathbf{F}^H \mathbf{f}(\mathbf{z}) &= \text{diag}(\hat{\mathbf{z}}) \mathbf{F}^H \mathbf{w} \\ \mathbf{F}^T \mathbf{f}(\mathbf{z}) &= \text{diag}(\hat{\mathbf{z}}^*) \mathbf{F}^T \mathbf{w} \\ \mathbf{F} \mathbf{f}(\mathbf{z}) &= \text{diag}(\hat{\mathbf{z}}^*) \mathbf{F} \mathbf{w}\end{aligned}\tag{29}$$

最后得到

$$\hat{\mathbf{f}}(\mathbf{z}) = \hat{\mathbf{z}}^* \odot \hat{\mathbf{w}}\tag{30}$$

实际上，式27与论文中的式子不一样（我觉得论文里写错了），我们对我们的公式可以做简单的验证，即令 \mathbf{z} 为原图，即 $\mathbf{z} = \mathbf{x}$ ，我们做个简单的检测

$$\begin{aligned}\hat{\mathbf{f}}(\mathbf{z}) &= \hat{\mathbf{z}}^* \odot \hat{\mathbf{w}} \\ &= \hat{\mathbf{x}}^* \odot \hat{\mathbf{w}} \\ &= \frac{\hat{\mathbf{x}}^* \odot \hat{\mathbf{x}}}{\hat{\mathbf{x}}^* \odot \hat{\mathbf{x}} + \lambda} \odot \hat{\mathbf{y}}\end{aligned}\tag{31}$$

令 $\lambda = 0$ 上式化为

$$\hat{\mathbf{f}}(\mathbf{z}) = \hat{\mathbf{y}}\tag{32}$$

即

$$\mathbf{f}(\mathbf{z}) = \mathbf{y}\tag{33}$$

这个结果是合理的。

1.4 核方法

这里我们利用核方法，利用映射 $\phi(\cdot)$ 将 \mathbf{x} 映射到非线性空间中。

1.4.1 岭回归

我们的优化对象仍然为

$$\min \sum_{i=1}^m (f(\mathbf{x}_i) - y_i)^2 + \lambda \|\mathbf{w}\|^2\tag{34}$$

根据表示定理（见西瓜书 137 页），这个问题的解，总可写为

$$f^*(\mathbf{x}) = \sum_{i=1}^m \alpha_i \kappa(\mathbf{x}, \mathbf{x}_i)\tag{35}$$

这里的 $*$ 不表示共轭，表示最优解。所以线性回归方程可写为

$$f(\mathbf{z}) = \mathbf{w}^T \phi(\mathbf{z}) \quad (36)$$

其中 \mathbf{w} 可写为

$$\mathbf{w} = \sum_{i=1}^m \alpha_i \phi(\mathbf{x}_i) \quad (37)$$

令核矩阵为 \mathbf{K} ，且 $K_{ij} = \kappa(\mathbf{x}_i, \mathbf{x}_j)$ 。

1.4.2 矩阵表示

把 \mathbf{w} 代入至线性回归方程得到

$$f(\mathbf{z}) = \sum_{i=1}^m \alpha_i \kappa(\mathbf{z}, \mathbf{x}_i) \quad (38)$$

优化对象为

$$\begin{aligned} & \min \sum_{i=1}^m \left(\sum_{j=1}^m \alpha_j \kappa(\mathbf{x}_i, \mathbf{x}_j) - y_i \right)^2 + \lambda \|\mathbf{w}\|^2 \\ & \min \sum_{i=1}^m \left(\sum_{j=1}^m \alpha_j K_{ij} - y_i \right)^2 + \lambda \|\mathbf{w}\|^2 \\ & \min \sum_{i=1}^m (\mathbf{K}_i^T \boldsymbol{\alpha} - y_i)^2 + \lambda \left(\sum_{i=1}^m \alpha_i \phi(\mathbf{x}_i) \right)^T \left(\sum_{i=1}^m \alpha_i \phi(\mathbf{x}_i) \right) \\ & \min (\mathbf{K}\boldsymbol{\alpha} - \mathbf{y})^T (\mathbf{K}\boldsymbol{\alpha} - \mathbf{y}) + \lambda \boldsymbol{\alpha}^T \mathbf{K} \boldsymbol{\alpha} \end{aligned} \quad (39)$$

可以看出我们的优化对象从 \mathbf{w} 变成了 $\boldsymbol{\alpha}$ ，我们称 $\boldsymbol{\alpha}$ 为对偶空间，而 \mathbf{w} 称为主空间。

1.4.3 求解

令 $J(\boldsymbol{\alpha}) = (\mathbf{K}\boldsymbol{\alpha} - \mathbf{y})^T (\mathbf{K}\boldsymbol{\alpha} - \mathbf{y}) + \lambda \boldsymbol{\alpha}^T \mathbf{K} \boldsymbol{\alpha}$ 对 $\boldsymbol{\alpha}$ 求偏导得到。

$$\begin{aligned} \frac{\partial J}{\partial \boldsymbol{\alpha}} &= 2\mathbf{K}^T \mathbf{K} \boldsymbol{\alpha} - 2\mathbf{K}^T \mathbf{y} + 2\lambda \mathbf{K} \boldsymbol{\alpha} \\ &= 2\mathbf{K}(\mathbf{K}\boldsymbol{\alpha} - \mathbf{y} + \lambda \boldsymbol{\alpha}) \end{aligned} \quad (40)$$

令偏导为零得

$$\boldsymbol{\alpha} = (\mathbf{K} + \lambda \mathbf{I})^{-1} \mathbf{y} \quad (41)$$

1.4.4 训练过程

若 \mathbf{K} 为循环矩阵，那么，式41也可类似之前一样简化。可以证明，当 $\kappa(\mathbf{x}, \mathbf{x}') = \kappa(\mathbf{x}, \mathbf{x}')$ 时， \mathbf{K} 为循环矩阵，即 K_{ij} 的值只与 $(i - j)$ 的值有关。证明如下。以下的 \mathbf{P} 在式1中定义。

$$\begin{aligned} K_{ij} &= \kappa(\mathbf{P}^i \mathbf{x}, \mathbf{P}^j \mathbf{x}) \\ &= \kappa(\mathbf{P}^{-i} \mathbf{P}^i \mathbf{x}, \mathbf{P}^{-i} \mathbf{P}^j \mathbf{x}) \\ &= \kappa(\mathbf{x}, \mathbf{P}^{j-i} \mathbf{x}) \end{aligned} \quad (42)$$

所以 K_{ij} 的值只与 $(i - j)$ 有关所以 \mathbf{K} 为循环矩阵。实际上线性核、RBF 核等都满足该性质。

所以可以对 \mathbf{K} 进行特征值分解。令 $\mathbf{k}^{\mathbf{x}\mathbf{x}}$ 为矩阵 \mathbf{K} 的第一行的转置，即 $k_i^{\mathbf{x}\mathbf{x}} = \kappa(\mathbf{x}, \mathbf{x}_i)$ 。

$$\begin{aligned}\boldsymbol{\alpha} &= (\mathbf{F} \text{diag}(\hat{\mathbf{k}}^{\mathbf{x}\mathbf{x}}) \mathbf{F}^H + \lambda \mathbf{F} \mathbf{F}^H) \mathbf{y} \\ &= \mathbf{F} \text{diag}\left(\frac{1}{\hat{\mathbf{k}}^{\mathbf{x}\mathbf{x}} + \lambda}\right) \mathbf{F}^H \mathbf{y} \\ \mathbf{F}^H \boldsymbol{\alpha} &= \text{diag}\left(\frac{1}{\hat{\mathbf{k}}^{\mathbf{x}\mathbf{x}} + \lambda}\right) \mathbf{F}^H \mathbf{y} \\ \hat{\boldsymbol{\alpha}} &= \text{diag}\left(\frac{1}{\hat{\mathbf{k}}^{\mathbf{x}\mathbf{x}} + \lambda}\right) \hat{\mathbf{y}}\end{aligned}\tag{43}$$

所以我们得到。

$$\hat{\boldsymbol{\alpha}} = \frac{\hat{\mathbf{y}}}{\hat{\mathbf{k}}^{\mathbf{x}\mathbf{x}} + \lambda}\tag{44}$$

1.4.5 检测过程

为方便，首先对 $\mathbf{k}^{\mathbf{x}\mathbf{x}'}$ （即，核相关向量）定义

$$k_i^{\mathbf{x}\mathbf{x}'} = \kappa(\mathbf{x}', \mathbf{P}^{i-1} \mathbf{x}) = \kappa(\mathbf{x}', \mathbf{x}_i)\tag{45}$$

观察式45和式38可以将式38如下化简

$$f(\mathbf{z}) = \sum_{i=1}^m \alpha_i k_i^{\mathbf{x}\mathbf{z}} = (\mathbf{k}^{\mathbf{x}\mathbf{z}})^T \boldsymbol{\alpha}\tag{46}$$

所以

$$\begin{aligned}\mathbf{f}(\mathbf{z}) &= \mathbf{C}(\mathbf{k}^{\mathbf{x}\mathbf{z}}) \boldsymbol{\alpha} \\ &= \mathbf{F} \text{diag}(\hat{\mathbf{k}}^{\mathbf{x}\mathbf{z}}) \mathbf{F}^H \boldsymbol{\alpha} \\ \mathbf{F}^H \mathbf{f} &= \text{diag}(\hat{\mathbf{k}}^{\mathbf{x}\mathbf{z}}) \mathbf{F}^H \boldsymbol{\alpha} \\ \mathbf{F} \mathbf{f} &= \text{diag}(\hat{\mathbf{k}}^{*\mathbf{x}\mathbf{z}}) \mathbf{F} \boldsymbol{\alpha} \\ \hat{\mathbf{f}} &= \text{diag}(\hat{\mathbf{k}}^{*\mathbf{x}\mathbf{z}}) \hat{\boldsymbol{\alpha}}\end{aligned}\tag{47}$$

最后可得

$$\hat{\mathbf{f}} = \hat{\mathbf{k}}^{*\mathbf{x}\mathbf{z}} \odot \hat{\boldsymbol{\alpha}}\tag{48}$$

1.5 核相关向量的计算

在训练过程，即式44和检测过程，即式48中，往往都是先将原始数据 \mathbf{x} 转化为核相关向量 $\mathbf{k}^{\mathbf{x}\mathbf{x}'}$ 再进行计算，这里给出内积核和径向基函数（RBF）核的简化计算方法。但并不是所有核都能有简化的方法。

1.5.1 内积核

内积核的形式为 $\kappa(\mathbf{x}, \mathbf{x}') = g(\mathbf{x}^T \mathbf{x}')$ ，结合式45可得

$$k_i^{\mathbf{x}\mathbf{x}'} = \kappa(\mathbf{x}', \mathbf{P}^{i-1} \mathbf{x}) = g((\mathbf{P}^{i-1} \mathbf{x})^T \mathbf{x}')\tag{49}$$

所以

$$\mathbf{k}^{\mathbf{x}\mathbf{x}'} = g(C(\mathbf{x})\mathbf{x}') \quad (50)$$

对 $C(\mathbf{x})$ 施行特征值分解可得,

$$\begin{aligned} \mathbf{k}^{\mathbf{x}\mathbf{x}'} &= g(\mathbf{F} \text{diag}(\hat{\mathbf{x}}) \mathbf{F}^H \mathbf{x}') \\ &= g(\mathbf{F} \text{diag}(\hat{\mathbf{x}}) (\mathbf{F}^T \mathbf{x}')^*) \\ &= g(\mathbf{F} \text{diag}(\hat{\mathbf{x}}) (\mathbf{F} \mathbf{x}')^*) \\ &= g\left(\frac{1}{\sqrt{N}} \mathbf{F} \text{diag}(\hat{\mathbf{x}}) \hat{\mathbf{x}}'^*\right) \\ &= g\left(\frac{1}{\sqrt{N}} (\mathbf{F}^H \text{diag}(\hat{\mathbf{x}}^*) \hat{\mathbf{x}}')^*\right) \\ &= g\left(\frac{1}{\sqrt{N}} (\mathbf{F}^H \hat{\mathbf{x}}^* \odot \hat{\mathbf{x}}')^*\right) \\ &= g\left((\mathcal{F}^{-1}(\hat{\mathbf{x}}^* \odot \hat{\mathbf{x}}'))^*\right) \end{aligned} \quad (51)$$

由于 \mathbf{x} 和 \mathbf{x}' 均为实序列, 所以 $\hat{\mathbf{x}}$ 和 $\hat{\mathbf{x}}'$ 必然都是共轭对称的序列, 所以 $\hat{\mathbf{x}}^* \odot \hat{\mathbf{x}}'$ 也是共轭对称的序列, 所以 $\hat{\mathbf{x}}^* \odot \hat{\mathbf{x}}'$ 的逆傅立叶变换必然是实序列, 即 $(\mathcal{F}^{-1}(\hat{\mathbf{x}}^* \odot \hat{\mathbf{x}}'))^* = \mathcal{F}^{-1}(\hat{\mathbf{x}}^* \odot \hat{\mathbf{x}}')$, 所以得到

$$\mathbf{k}^{\mathbf{x}\mathbf{x}'} = g\left(\mathcal{F}^{-1}(\hat{\mathbf{x}}^* \odot \hat{\mathbf{x}}')\right) \quad (52)$$

实际上, 式53也是在推导中常用的。

$$C(\mathbf{x})\mathbf{x}' = \mathcal{F}^{-1}(\hat{\mathbf{x}}^* \odot \hat{\mathbf{x}}') \quad (53)$$

特别的, 我们可以写出多项式核 $\kappa(\mathbf{x}, \mathbf{x}') = (\mathbf{x}^T \mathbf{x}' + a)^b$ 的核向量为

$$\mathbf{k}^{\mathbf{x}\mathbf{x}'} = \left(\mathcal{F}^{-1}(\hat{\mathbf{x}}^* \odot \hat{\mathbf{x}}') + a\right)^b \quad (54)$$

线性核 $\kappa(\mathbf{x}, \mathbf{x}') = \mathbf{x}^T \mathbf{x}'$ 的核向量为

$$\mathbf{k}^{\mathbf{x}\mathbf{x}'} = \mathcal{F}^{-1}(\hat{\mathbf{x}}^* \odot \hat{\mathbf{x}}') \quad (55)$$

可以看出, 核向量的计算也被简化为 $O(n \log n)$ 的时间复杂度了

1.5.2 径向基函数核

内积核的形式为 $\kappa(\mathbf{x}, \mathbf{x}') = h(\|\mathbf{x} - \mathbf{x}'\|^2)$, 结合式45可得

$$k_i^{\mathbf{x}\mathbf{x}'} = \kappa(\mathbf{x}', \mathbf{P}^{i-1} \mathbf{x}) = h(\|\mathbf{x}' - \mathbf{P}^{i-1} \mathbf{x}\|^2) \quad (56)$$

将上式展开得到

$$k_i^{\mathbf{x}\mathbf{x}'} = h(\|\mathbf{x}'\|^2 + \|\mathbf{x}\|^2 - 2(\mathbf{P}^{i-1} \mathbf{x})^T \mathbf{x}') \quad (57)$$

写成向量形式

$$\mathbf{k}^{\mathbf{x}\mathbf{x}'} = h(\|\mathbf{x}'\|^2 + \|\mathbf{x}\|^2 - 2C(\mathbf{x})\mathbf{x}') \quad (58)$$

将式53代入上式得到

$$\mathbf{k}^{\mathbf{x}\mathbf{x}'} = h \left(\|\mathbf{x}'\|^2 + \|\mathbf{x}\|^2 - 2\mathcal{F}^{-1}(\hat{\mathbf{x}}^* \odot \hat{\mathbf{x}}') \right) \quad (59)$$

特殊的，考虑高斯核 $\kappa(\mathbf{x}, \mathbf{x}') = \exp(-\frac{1}{\sigma^2} \|\mathbf{x} - \mathbf{x}'\|^2)$

$$\mathbf{k}^{\mathbf{x}\mathbf{x}'} = \exp \left(-\frac{1}{\sigma^2} \left(\|\mathbf{x}'\|^2 + \|\mathbf{x}\|^2 - 2\mathcal{F}^{-1}(\hat{\mathbf{x}}^* \odot \hat{\mathbf{x}}') \right) \right) \quad (60)$$

该式同样是一个 $O(n \log n)$ 时间复杂度的式子。

1.6 拓展至多通道问题

若原始图像是彩色图像，或者我们不用原始图像去做特征而是用提取的特征（如 HOG 特征），这样我们就会面临多通道问题，之前的所有推导都是建立在多通道问题上的，这样我们就需要对我们的结果进行修改使其能够适应多通道问题。

假设特征有 C 个通道， $\mathbf{x}_1, \dots, \mathbf{x}_C$ ，为了能够将其能够适用式44和式48，需用核函数将其转为式45的核相关向量形式，在第1.5部分我们对内积核和 RBF 核做了讨论，其中只牵扯到对原始向量的求范数和内积的操作，这两种操作可以很容易拓展至多通道。

$$\|\mathbf{x}\|^2 = \sum_{i=1}^C \|\mathbf{x}_i\|^2 \quad (61)$$

$$\mathbf{x}^T \mathbf{x}' = \sum_{i=1}^C \mathbf{x}_i^T \mathbf{x}' \quad (62)$$

所以式55可写为

$$\mathbf{k}^{\mathbf{x}\mathbf{x}'} = \mathcal{F}^{-1} \left(\sum_{c=1}^C \hat{\mathbf{x}}_c^* \odot \hat{\mathbf{x}}'_c \right) \quad (63)$$

式60可写为

$$\mathbf{k}^{\mathbf{x}\mathbf{x}'} = \exp \left(-\frac{1}{\sigma^2} \left(\|\mathbf{x}'\|^2 + \|\mathbf{x}\|^2 - 2\mathcal{F}^{-1} \left(\sum_{c=1}^C \hat{\mathbf{x}}_c^* \odot \hat{\mathbf{x}}'_c \right) \right) \right) \quad (64)$$

1.7 对偶相关滤波器

我们使用线性核 $\kappa(\mathbf{x}, \mathbf{x}') = \mathbf{x}^T \mathbf{x}'$ 时，核相关向量的表示为式63，训练过程为式44，检测过程为式48，我们称这套 tracking 方法为对偶相关滤波器，因为它是线性的，并且是在对偶空间 α 训练的。

1.8 总结

核相关滤波器 (KCF) 和对偶相关滤波器 (DCF) 与其他滤波器相比，最大的特点是速度快，同时也保证了准确性，从图2可以看出。

总之这篇论文行文非常顺畅，数学推导非常优美（但是有些地方似乎推导的不对？可能是我错了？），效果也非常好，可以说是 tracking 类论文的经典了！

	Algorithm	Feature	Mean precision (20 px)	Mean FPS
Proposed	KCF	HOG	73.2%	172
	DCF		72.8%	292
	KCF	Raw pixels	56.0%	154
	DCF		45.1%	278
Other algorithms	Struck [7]		65.6%	20
	TLD [4]		60.8%	28
	MOSSE [9]		43.1%	615
	MIL [5]		47.5%	38
	ORIA [14]		45.7%	9
	CT [3]		40.6%	64

Table 1: Summary of experimental results on the 50 videos dataset. The reported quantities are averaged over all videos. Reported speeds include feature computation (e.g. HOG).

图 2: 算法对比