

Camera Model Note

FanmingL

2018 年 11 月 28 日




图 1: 示例图




图 2: 相机坐标系下的坐标到像素坐标的转换，图源水印

1 相机模型

1.1 问题的提出

如图1，当我们拍摄地面时，若我们知道图中白线的规格（长度以及间隔），如何推算图中所有像素点在地面上的坐标（当然这要先假设图中所有物体都在地面上）？

要解决这个问题，还得首先从相机模型开始理解。

1.2 相机模型

1.2.1 相机内参

就假设我们的成像满足小孔成像模型，见图2。由这个模型很容易推出，在相机坐标系下坐标为 $[x, y, z]^T$ 的点，是如何映射到像素坐标上的。

见图2的右图，其中右上角的黑点表示我们观测的点，经过 p 点的竖线表示我们的感光片，我们的光线打到感光片上就能成像，在感光片上的位置可以由这个模型去确认，图2的右图中标出了 Y, Z 轴的方向，这就是相机坐标系的 Y, Z 轴， cp 的长度为焦距，通过相似三角形原则我们可以确定，该物体在像素平面上的纵的像素坐标 v 为

$$v = \frac{fy}{z} \quad (1)$$

同理，横的像素坐标 u

$$u = \frac{fx}{z} \quad (2)$$

上面求出的是以相机正中心为原点求出的坐标，而我们的图像的原点在图像的左上角，所以还需要加个偏移量，使我们求出图像原点在左上角的坐标，假设偏移分别为 u_0, v_0 。

$$v = \frac{fy}{z} + v_0 \quad (3)$$

$$u = \frac{fx}{z} + u_0 \quad (4)$$

但是到这里还不是我们想要的，因为以上坐标的单位是厘米或者毫米，我们需要的是像素坐标，要转化为像素坐标，就需要知道感光片上的传感器的间隔，即传感器之间的实际间隔，假设分别为 d_u, d_v 。

$$v = \frac{\frac{fy}{z} + v_0}{d_v} \quad (5)$$

$$u = \frac{\frac{fx}{z} + u_0}{d_u} \quad (6)$$

稍作整理

$$v = \frac{\frac{f}{d_v}}{z} y + \frac{v_0}{d_v} \quad (7)$$

$$u = \frac{\frac{f}{d_u}}{z} x + \frac{u_0}{d_u} \quad (8)$$

令

$$\begin{aligned} f_y &= \frac{f}{d_v} \\ f_x &= \frac{f}{d_u} \\ c_y &= \frac{v_0}{d_v} \\ c_x &= \frac{u_0}{d_u} \end{aligned} \quad (9)$$

得到

$$v = \frac{f_y}{z} y + c_y \quad (10)$$

$$u = \frac{f_x}{z} x + c_x \quad (11)$$

其实这个能够写成矩阵形式

$$z \begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = \begin{bmatrix} f_x & 0 & c_x \\ 0 & f_y & c_y \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x \\ y \\ z \end{bmatrix} \quad (12)$$

令

$$\mathbf{K} = \begin{bmatrix} f_x & 0 & c_x \\ 0 & f_y & c_y \\ 0 & 0 & 1 \end{bmatrix} \quad (13)$$

写得更原始点就是

$$\mathbf{K} = \begin{bmatrix} \frac{f}{d_u} & 0 & \frac{u_0}{d_u} \\ 0 & \frac{f}{d_v} & \frac{v_0}{d_v} \\ 0 & 0 & 1 \end{bmatrix} \quad (14)$$

因为 \mathbf{K} 只与相机本身的性质（焦距、主点偏移量、传感器间隔）有关，我们称 \mathbf{K} 为相机内参。

在我们调整相机焦距时 f 会发生改变，调整相机分辨率时 d_u, d_v 会发生改变，这点希望能够记住，调整相机分辨率之后实际上不需要重新标定相机，只需要对内参矩阵做一些小修改即可。

1.2.2 相机外参

上一节我们知道只要对相机坐标系下的坐标 $[x, y, z]$ 左乘一个相机内参矩阵，再把坐标转为齐次坐标（即把结果向量的第三项归一化），就能够得到像素坐标。但是，相机总是运动的，我们很难确定某个物体在相机坐标系下的坐标，但是我们能够给定一个世界坐标系，一个静止的物体在世界坐标系下的坐标肯定是固定的。

为了方便区分，令相机坐标系下的坐标为 $[x_c, y_c, z_c]^T$ ，世界坐标系下的坐标为 $[x_w, y_w, z_w]^T$ 。那么式12应当写为

$$z_c \begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = \begin{bmatrix} f_x & 0 & c_x \\ 0 & f_y & c_y \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x_c \\ y_c \\ z_c \end{bmatrix} \quad (15)$$

我们知道在三维世界中，一个坐标系到另一个坐标系的变换可以由一个旋转和一个平移表示，即

$$\begin{bmatrix} x_c \\ y_c \\ z_c \end{bmatrix} = \mathbf{R} \begin{bmatrix} x_w \\ y_w \\ z_w \end{bmatrix} + \mathbf{t} \quad (16)$$

其中 \mathbf{R} 为旋转矩阵， \mathbf{t} 为平移向量， \mathbf{R} 有以下性质

$$\begin{aligned} \mathbf{R}^T \mathbf{R} &= \mathbf{I} \\ |\mathbf{R}| &= 1 \end{aligned} \quad (17)$$

式16其实可以这样理解：先把世界坐标系做个旋转，使得三个基矢和相机坐标系的平行，再直接将世界坐标系的原点平移至相机坐标系处。为了方便，式16可写成矩阵形式。

$$\begin{bmatrix} x_c \\ y_c \\ z_c \end{bmatrix} = [\mathbf{R} \quad \mathbf{t}] \begin{bmatrix} x_w \\ y_w \\ z_w \\ 1 \end{bmatrix} \quad (18)$$

上式也可以写成齐次的形式

$$\begin{bmatrix} x_c \\ y_c \\ z_c \\ 1 \end{bmatrix} = \begin{bmatrix} \mathbf{R} & \mathbf{t} \\ \mathbf{0}^T & 1 \end{bmatrix} \begin{bmatrix} x_w \\ y_w \\ z_w \\ 1 \end{bmatrix} \quad (19)$$

令

$$\mathbf{M} = \begin{bmatrix} \mathbf{R} & \mathbf{t} \\ \mathbf{0}^T & 1 \end{bmatrix} \quad (20)$$

由于 \mathbf{M} 只和相机的位姿有关，我们称 \mathbf{M} 为相机外参，由于矩阵 \mathbf{R} 的特殊正交性， \mathbf{M} 的逆可以很快写出

$$\mathbf{M}^{-1} = \begin{bmatrix} \mathbf{R}^T & \mathbf{R}^T \mathbf{t} \\ \mathbf{0}^T & 1 \end{bmatrix} \quad (21)$$

至此我们可以将相机成像的全部流程用一个公式写出

$$z_c \begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = \mathbf{K} [\mathbf{R} \quad \mathbf{t}] \begin{bmatrix} x_w \\ y_w \\ z_w \\ 1 \end{bmatrix} \quad (22)$$

上述模型是很多单目视觉定位的基础，比如视觉 SLAM。

1.3 单应性矩阵

考虑一个特殊情况，我们拍摄的所有东西都在一个平面上，然后我们以这个平面为世界坐标系的 xy 平面，那么这个平面上所有的点的 z_w 都为零。代入至式22得到

$$z_c \begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = \mathbf{K} [\mathbf{R} \quad \mathbf{t}] \begin{bmatrix} x_w \\ y_w \\ 0 \\ 1 \end{bmatrix} \quad (23)$$

我们把旋转矩阵分块写，令 $\mathbf{R} = [\mathbf{r}_1, \mathbf{r}_2, \mathbf{r}_3]$ ，上式可写成如下

$$z_c \begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = \mathbf{K} \begin{bmatrix} \mathbf{r}_1 & \mathbf{r}_2 & \mathbf{r}_3 & \mathbf{t} \end{bmatrix} \begin{bmatrix} x_w \\ y_w \\ 0 \\ 1 \end{bmatrix} \quad (24)$$

因为有个零存在，上式可继续化简

$$z_c \begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = \mathbf{K} \begin{bmatrix} \mathbf{r}_1 & \mathbf{r}_2 & \mathbf{t} \end{bmatrix} \begin{bmatrix} x_w \\ y_w \\ 1 \end{bmatrix} \quad (25)$$

令

$$\mathbf{H} = \mathbf{K} \begin{bmatrix} \mathbf{r}_1 & \mathbf{r}_2 & \mathbf{t} \end{bmatrix} \quad (26)$$

式25可写为

$$z_c \begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = \mathbf{H} \begin{bmatrix} x_w \\ y_w \\ 1 \end{bmatrix} \quad (27)$$

我们称 \mathbf{H} 为单应性矩阵。单应性变换通常描述从一个平面到另一个平面的变换，它的特点是，一个直线变换过去之后仍然是一根直线。

可以看出，该矩阵的尺度的变化（ \mathbf{H} 乘上一个标量）并不会影响这个变换关系，所以 \mathbf{H} 有八个自由度，要解出它来，至少需要八个方程。而解出它之后有两种使用方法。

第一种是我们在开篇设定的问题，匹配到若干特征点之后如何将其他像素点也映射到目标平面。

第二种是估计相机的位置，对式26两边同时乘以 \mathbf{K}^{-1}

$$\begin{bmatrix} \mathbf{r}_1 & \mathbf{r}_2 & \mathbf{t} \end{bmatrix} = \mathbf{K}^{-1} \mathbf{H} \quad (28)$$

由于 \mathbf{R} 的正交特性，我们可以很快由 $\mathbf{r}_1, \mathbf{r}_2$ 求出 \mathbf{r}_3

$$\mathbf{r}_3 = \mathbf{r}_1 \times \mathbf{r}_2 \quad (29)$$

其中 \times 代表叉乘（外积）。

求得旋转矩阵 \mathbf{R} 后，我们可以得到其旋转对应的四元数。

$$\begin{aligned} q_0 &= \frac{\sqrt{1 + \text{Tr}(\mathbf{R})}}{2} \\ q_1 &= \frac{R_{32} - R_{23}}{4q_0} \\ q_2 &= \frac{R_{13} - R_{31}}{4q_0} \\ q_3 &= \frac{R_{21} - R_{12}}{4q_0} \end{aligned} \quad (30)$$

相机相对于世界坐标系的旋转、平移便可由此估计出来！

1.4 单应性矩阵的最小二乘解

这部分主要推导当已经有若干点对之时，如何估计单应性矩阵 \mathbf{H}

1.4.1 优化目标

假设我们有 m 个点对 ($m \geq 4$)，我们可以得到 m 个式27，写成式子的形式即

$$\begin{aligned} u_i &= \frac{H_{11}x_i + H_{12}y_i + H_{13}}{H_{31}x_i + H_{32}y_i + H_{33}} \\ v_i &= \frac{H_{21}x_i + H_{22}y_i + H_{23}}{H_{31}x_i + H_{32}y_i + H_{33}} \end{aligned} \quad (31)$$

分母乘到左边，并移项。

$$\begin{aligned} H_{31}x_i u_i + H_{32}y_i u_i + H_{33}u_i - H_{11}x_i - H_{12}y_i - H_{13} &= 0 \\ H_{31}x_i v_i + H_{32}y_i v_i + H_{33}v_i - H_{21}x_i - H_{22}y_i - H_{23} &= 0 \end{aligned} \quad (32)$$

稍作整理

$$\begin{aligned} -H_{11}x_i - H_{12}y_i - H_{13} + H_{31}x_i u_i + H_{32}y_i u_i + H_{33}u_i &= 0 \\ -H_{21}x_i - H_{22}y_i - H_{23} + H_{31}x_i v_i + H_{32}y_i v_i + H_{33}v_i &= 0 \end{aligned} \quad (33)$$

又可以写成矩阵的形式

$$\begin{aligned} \mathbf{a}_{xi}^T \mathbf{h} &= 0 \\ \mathbf{a}_{yi}^T \mathbf{h} &= 0 \end{aligned} \quad (34)$$

其中

$$\begin{aligned} \mathbf{h} &= (H_{11}, H_{12}, H_{13}, H_{21}, H_{22}, H_{23}, H_{31}, H_{32}, H_{33})^T \\ \mathbf{a}_{xi} &= (-x_i, -y_i, -1, 0, 0, 0, x_i u_i, y_i u_i, u_i)^T \\ \mathbf{a}_{yi} &= (0, 0, 0, -x_i, -y_i, -1, x_i v_i, y_i v_i, v_i)^T \end{aligned} \quad (35)$$

我们的优化对象即

$$\min \sum_{i=1}^m (\mathbf{a}_{xi}^T \mathbf{h})^2 + (\mathbf{a}_{yi}^T \mathbf{h})^2 \quad (36)$$

将上式写成矩阵形式即

$$\min \|\mathbf{A}\mathbf{h}\|_2^2 \quad (37)$$

其中

$$A = \begin{bmatrix} \mathbf{a}_{x1}^T \\ \mathbf{a}_{y1}^T \\ \vdots \\ \mathbf{a}_{xm}^T \\ \mathbf{a}_{ym}^T \end{bmatrix} \quad (38)$$

式37就是我们的优化对象。

1.4.2 用 SVD 求解问题

把式37写成矩阵乘法的形式

$$\min J(\mathbf{h}) = \mathbf{h}^T \mathbf{A}^T \mathbf{A} \mathbf{h} \quad (39)$$

令 $J(\mathbf{h})$ 对 \mathbf{h} 求偏导。

$$\frac{\partial J(\mathbf{h})}{\partial \mathbf{h}} = 2\mathbf{A}^T \mathbf{A} \mathbf{h} \quad (40)$$

令偏导为零

$$\mathbf{A}^T \mathbf{A} \mathbf{h} = 0 \quad (41)$$

这实际上是一个求解齐次方程组的问题， $\mathbf{A}^T \mathbf{A}$ 为 9×9 的矩阵，若 $\mathbf{A}^T \mathbf{A}$ 的秩为 8，那么我们可以得到一个 \mathbf{h} 的非平凡解，这样就再好不过了。若 $\mathbf{A}^T \mathbf{A}$ 的秩小于 8，这种情况下，我们不能得到一个准确的答案。但是若我们提供 4 对以上不共线的点对构成 \mathbf{A} ， $\mathbf{A}^T \mathbf{A}$ 往

往是满秩的， \mathbf{h} 只有零解，所以我们需要对 $\mathbf{A}^T \mathbf{A}$ 进行些改造，让其不满秩。如何改造呢？首先观察 \mathbf{A} 的奇异值分解的形式。

$$\mathbf{A} = \mathbf{U} \Sigma \mathbf{V}^T \quad (42)$$

$\mathbf{A}^T \mathbf{A}$ 便可化为

$$\mathbf{A}^T \mathbf{A} = \mathbf{V} \Sigma^T \Sigma \mathbf{V}^T \quad (43)$$

设 Σ 的第 i 行 i 列的值（即， \mathbf{A} 的第 i 个奇异值）为 σ_i 。 \mathbf{v}_i 为 \mathbf{V} 的第 i 列。上式化为

$$\mathbf{A}^T \mathbf{A} = \sum_{i=1}^9 \sigma_i^2 \mathbf{v}_i \mathbf{v}_i^T \quad (44)$$

$\mathbf{v}_i \mathbf{v}_i^T$ 的秩必然为 1，上式的含义为 $\mathbf{A}^T \mathbf{A}$ 由 9 个秩为 1 的矩阵相加得到，所以使 $\mathbf{A}^T \mathbf{A}$ 不满秩的最简单的方法即，去掉其中一个矩阵，使新的矩阵由剩下的 8 个矩阵相加得到。8 个秩为 1 的矩阵之和的矩阵，其秩必然小于等于 8，而 $\mathbf{A}^T \mathbf{A}$ 为 9×9 的矩阵，此时 $\mathbf{A}^T \mathbf{A}$ 必不满秩。

假设我们去掉第 ℓ 个矩阵，式41化为

$$\begin{aligned} (\mathbf{A}^T \mathbf{A} - \sigma_\ell^2 \mathbf{v}_\ell \mathbf{v}_\ell^T) \mathbf{h} &= 0 \\ \mathbf{A}^T \mathbf{A} \mathbf{h} &= \sigma_\ell^2 \mathbf{v}_\ell \mathbf{v}_\ell^T \mathbf{h} \end{aligned} \quad (45)$$

现在问题的解转化为矩阵 $\mathbf{A}^T \mathbf{A}$ ， $\mathbf{v}_\ell \mathbf{v}_\ell^T$ 的泛化特征值的问题，不过，这里情况特殊，我们可以直接写出一个解。即

$$\mathbf{h} = \mathbf{v}_\ell \quad (46)$$

我们可以验证一下这个解的正确性

$$\begin{aligned} \mathbf{A}^T \mathbf{A} \mathbf{h} &= \sum_{i=1}^9 \sigma_i^2 \mathbf{v}_i \mathbf{v}_i^T \mathbf{h} \\ &= \sigma_\ell^2 \mathbf{v}_\ell \\ \sigma_\ell^2 \mathbf{v}_\ell \mathbf{v}_\ell^T \mathbf{h} &= \sigma_\ell^2 \mathbf{v}_\ell \mathbf{v}_\ell^T \mathbf{v}_\ell \\ &= \sigma_\ell^2 \mathbf{v}_\ell \end{aligned} \quad (47)$$

上式用到了 \mathbf{V} 的正交性，即

$$\mathbf{v}_i^T \mathbf{v}_j = \delta_{ij} \quad (48)$$

当且仅当 $i = j$ 时 $\delta_{ij} = 1$ ，其余 $\delta_{ij} = 0$ 。

那么应该怎么取 ℓ 呢？我们把式46代回到式39中，得到

$$\begin{aligned} \min \quad & \mathbf{v}_\ell^T \mathbf{A}^T \mathbf{A} \mathbf{v}_\ell \\ \min \quad & \mathbf{v}_\ell^T \sigma_\ell^2 \mathbf{v}_\ell \\ \min \quad & \sigma_\ell^2 \end{aligned} \quad (49)$$

所以我们要取最小的奇异值对应的下标作为 ℓ ，得益于 SVD 算法的高效性，在 Σ 中，奇异值已经按从大到小的顺序排列好了， σ_9 就是最小的奇异值，所以 $\ell = 9$ ，所以，

$$\mathbf{h} = \mathbf{v}_9 \quad (50)$$

即 \mathbf{V} 的第 9 列。

1.4.3 总结流程

所以我们拿到 $m(m \geq 4)$ 对不共线的点对之后，首先将其整理成式38的形式，然后对 \mathbf{A} 进行奇异值分解，取 \mathbf{V} 的最后一列作为 \mathbf{h} 的估计量即可！